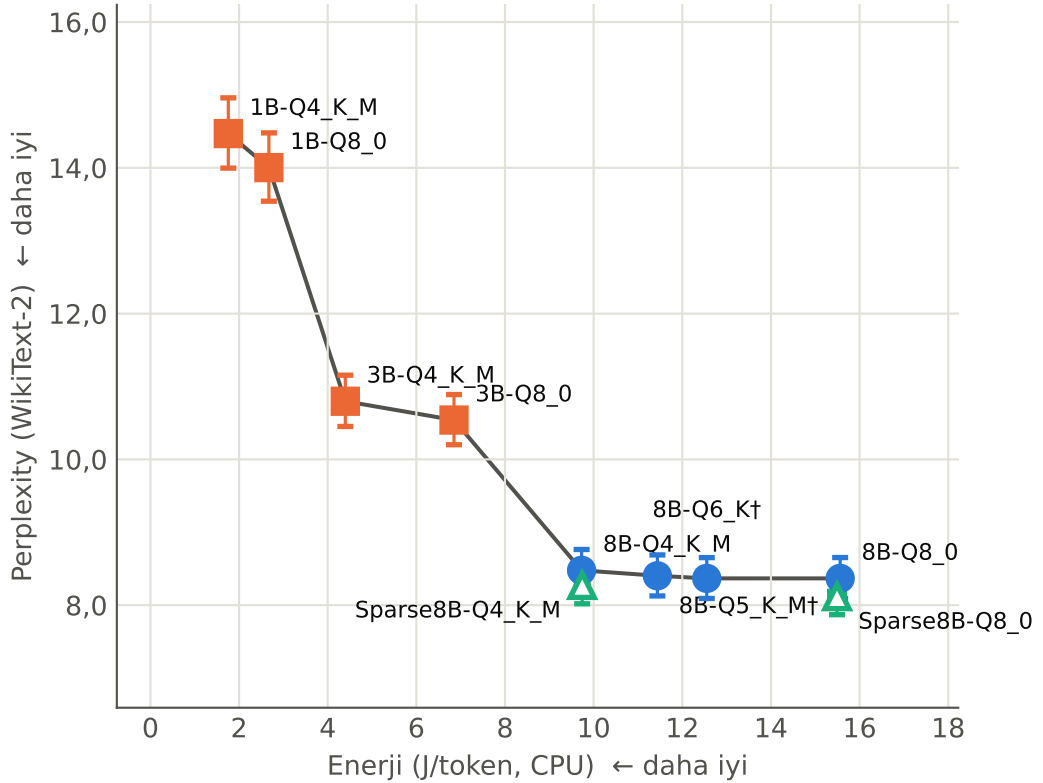

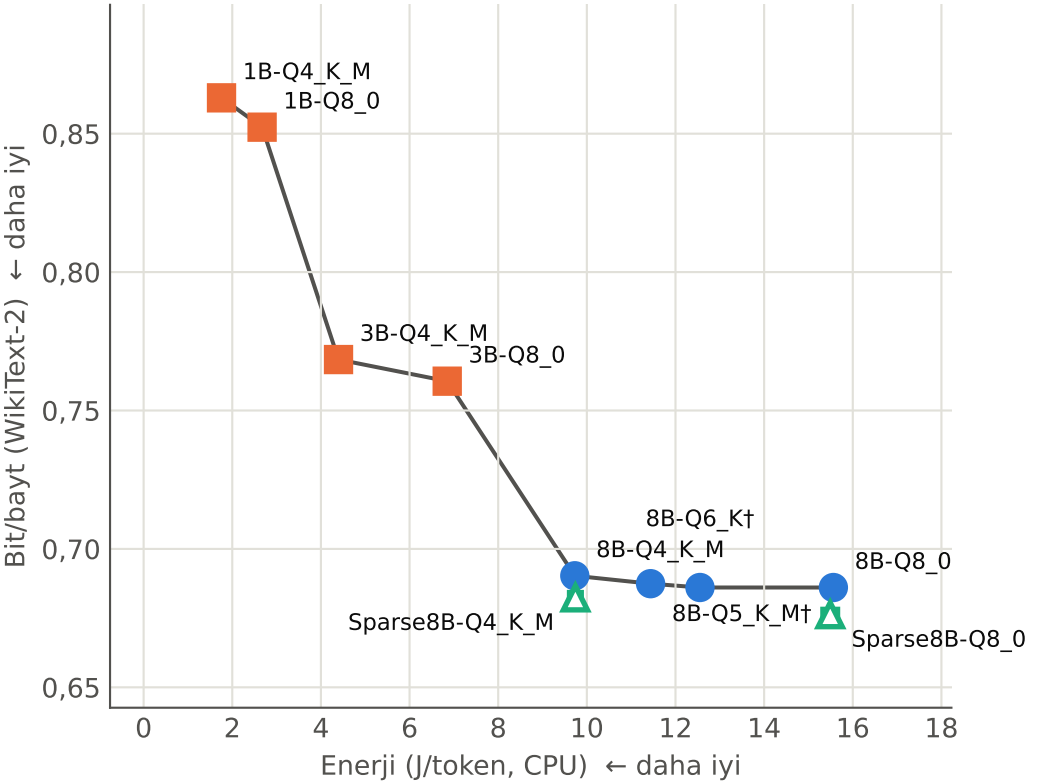

nicemleme · budama + damıtma · 2:4 seyrek budama + damıtma · temel (base) model · Pareto cephesi (instruct modeller)

Yatay hata çubuğu: oturumlar arası ±1 SS (n = 3). Dikey hata çubuğu: perplexity için parça düzeyinde %95 güven aralığı (564 parça, WikiText-2 testinin tamamı).
Pareto cephesi yalnızca instruct modeller arasında; temel model içi boş. † 8B-Q5_K_M ve 8B-Q6_K aynı gece (night_01, 10 tur) ölçüldü;
J/token değerleri çapa modeller (8B-Q4_K_M, 8B-Q8_0) üzerinden kampanya ölçeğine normalize edildi.