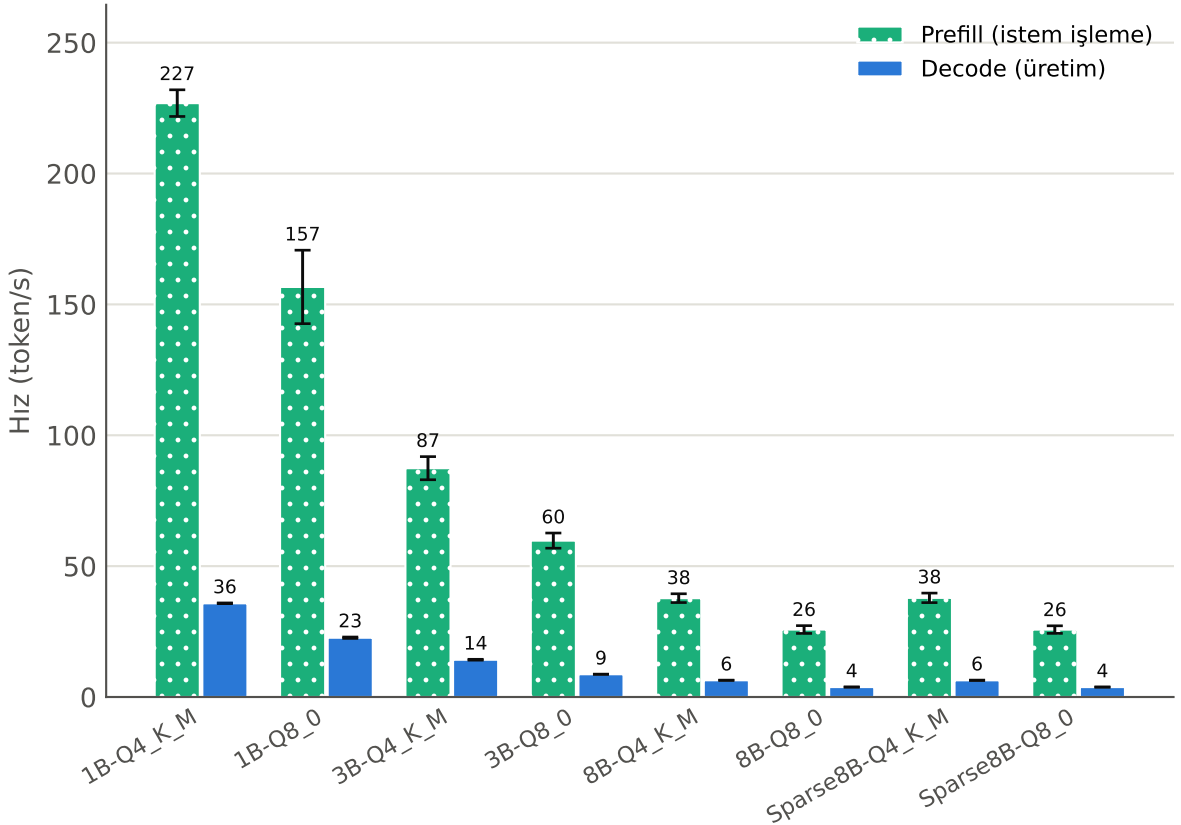

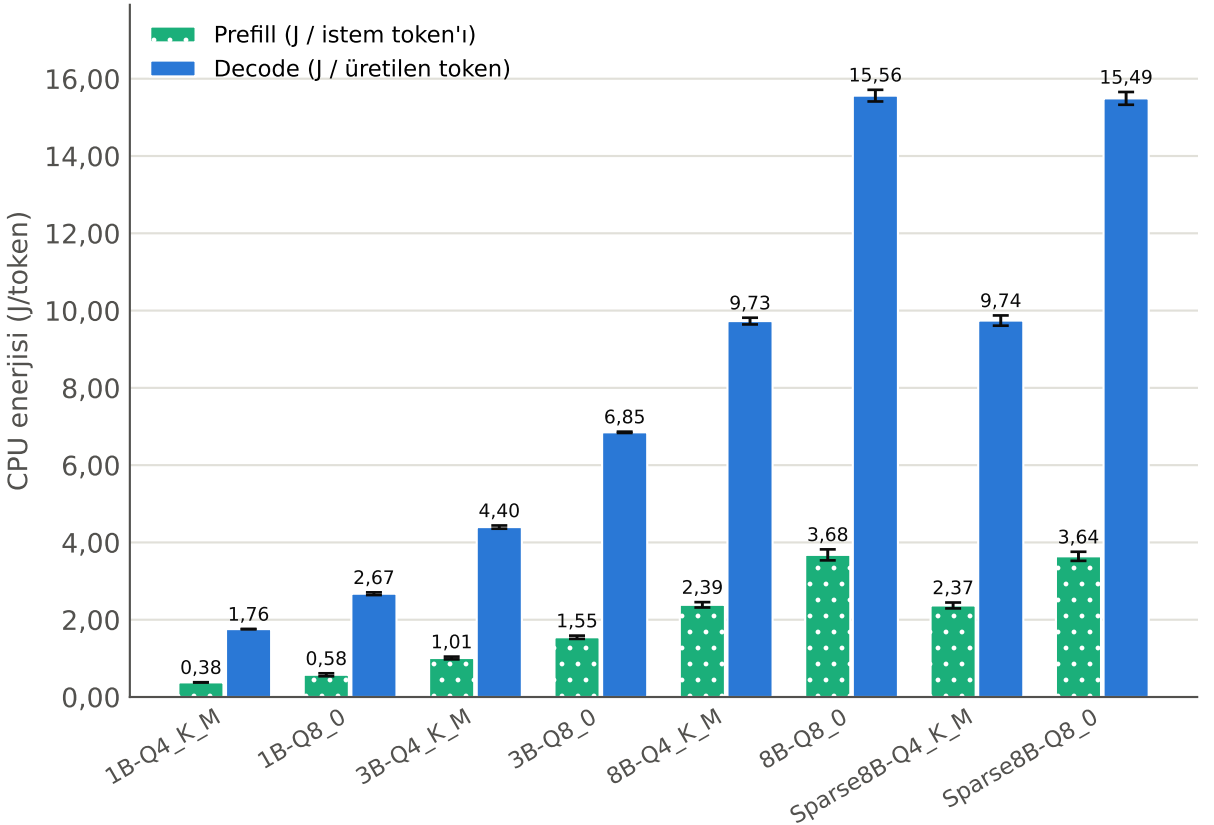

Çubuk: üç oturumun ortalaması; hata çubuğu: oturumlar arası ±1 SS (n = 3). Prefill 11–18 token'lık istemler üzerinde ölçülmüştür (tek ileri geçiş, hesaplamaya bağlı); decode 100 token üretimidir. Sağ panel: prefill penceresinin CPU enerjisi / istem token'ı ile decode J/token. 8 iş parçacığı.