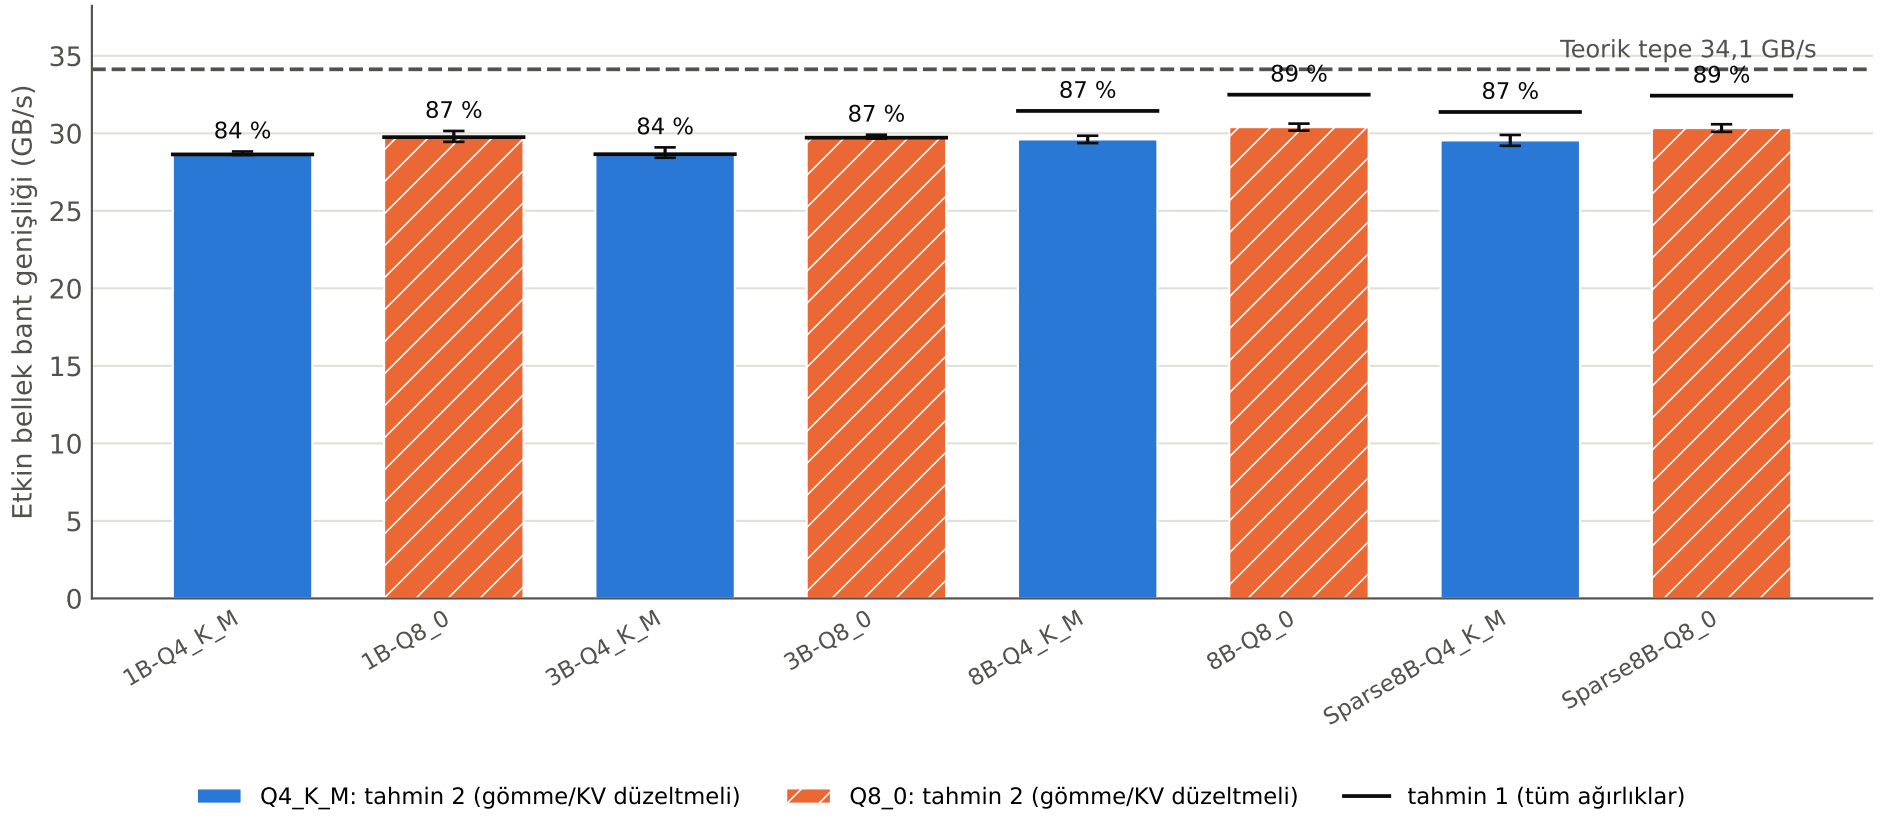

Çubuk: düzeltilmiş tahmin (ağırlıklar − satır bazlı okunan gömme tablosu + KV önbelleği) × decode token/s (üç oturumun ortalaması, 8 iş parçacığı); hata çubuğu oturumlar arası ±1 SS. Kısa çizgi: tüm ağırlıkların her token'da okunduğu varsayımı (tahmin 1). Yüzdeler teorik tepeye orandır.