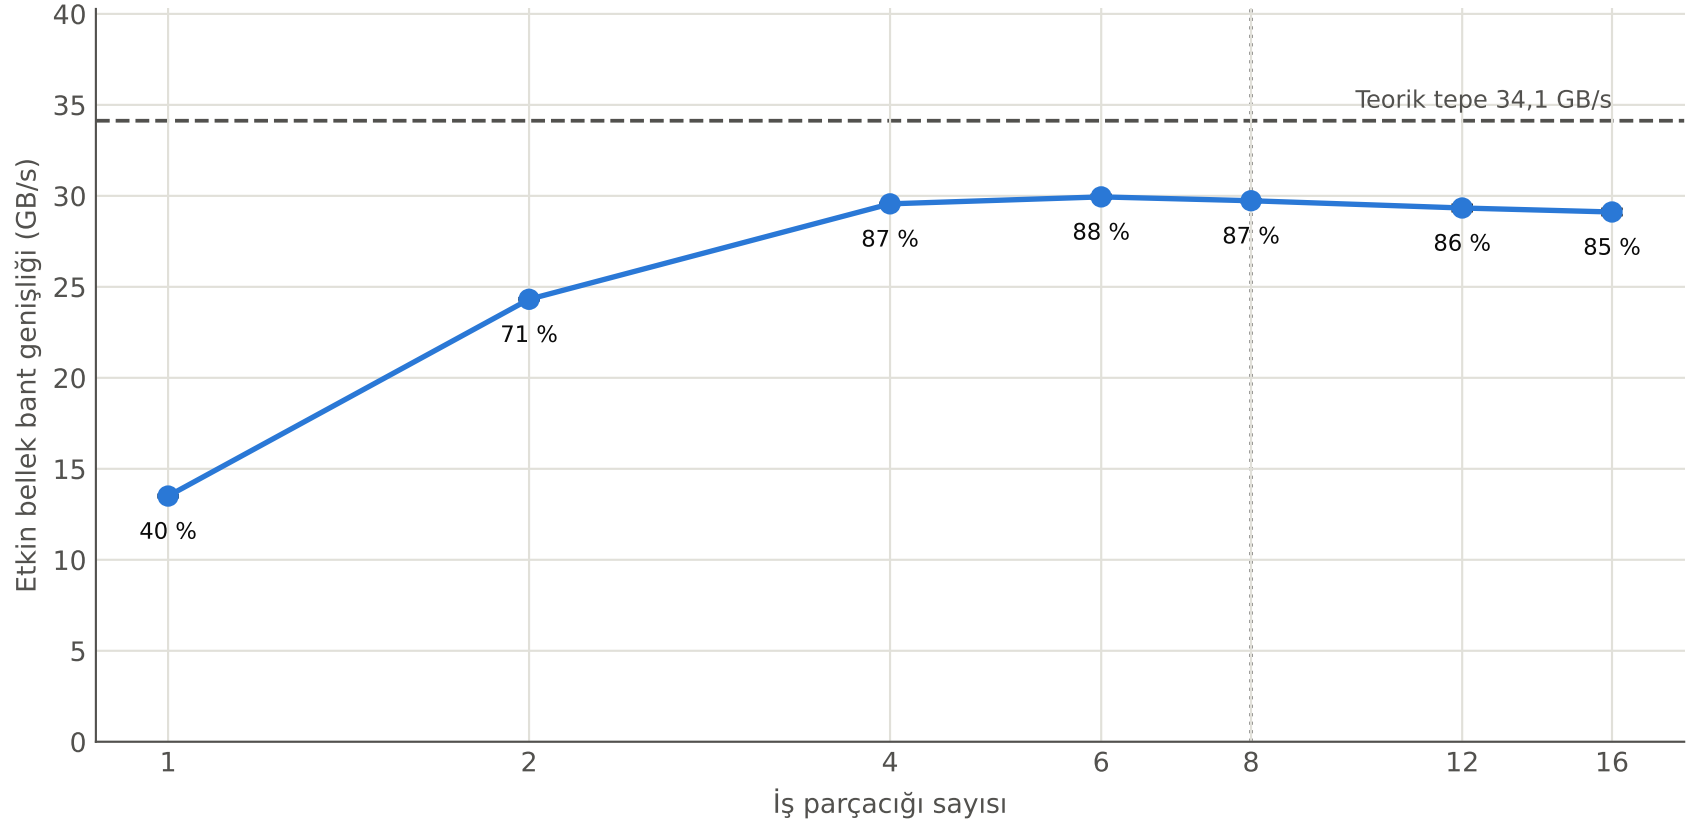

8B-Q4_K_M, düzeltilmiş bayt/token tahmini × decode token/s; hata çubuğu oturumlar arası ±1 SS (n = 3). Kesikli yatay çizgi: teorik tepe (2 kanal × 64 bit × 2133 MT/s).