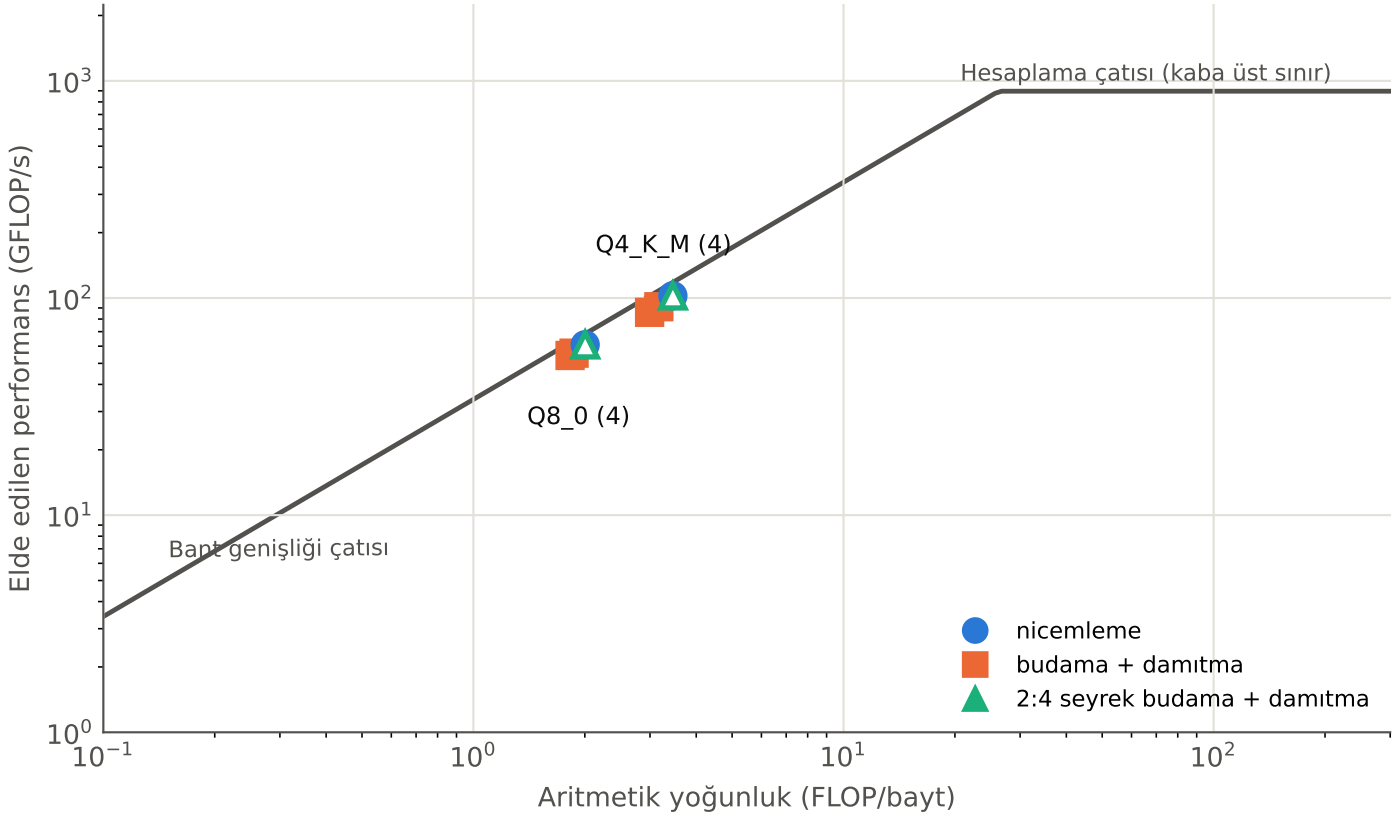

Kaba roofline: aritmetik yoğunluk = 2 × parametre sayısı / düzeltilmiş bayt/token; elde edilen performans = 2 × parametre × token/s. Hesaplama çatısı AVX2 fp32 FMA üst sınırıdır (8 çekirdek × 3,5 GHz); nicemlenmiş çekirdekler bu sınıra ulaşmaz, bu yüzden yalnızca bant genişliği çatısı nicel olarak anlamlıdır.